



Distribuciones y Análisis Univariado - Día 3

Change Status

in-progress 40 min

Learning Objectives

- 1 Identificar y caracterizar diferentes tipos de distribuciones en datos reales
- 2 Calcular e interpretar medidas de forma: asimetría y curtosis
- 3 Aplicar métodos estadísticos para detección sistemática de outliers

Theory

Practice

Quiz

Evidence

Actividades y Aprendizajes

Aprende todo sobre funciones y módulos en Python con ejemplos prácticos.

Task 1: Tipos Comunes de Distribuciones (12 minutos)

Las distribuciones de datos reales siguen **patrones reconocibles** que revelan procesos subyacentes. Comprender estos patrones permite seleccionar análisis apropiados y detectar anomalías significativas.

Distribución Normal (Gaussiana): El Patrón de Equilibrio

La distribución normal es la **distribución más famosa** de la estadística, caracterizada por su **curva de campana simétrica**.

Características:

Simétrica: Media = Mediana = Moda

Forma de campana: La mayoría de valores cerca del centro

Definida por dos parámetros: Media (μ) y desviación estándar (σ)

Regla empírica: 68% dentro 1σ , 95% dentro 2σ , 99.7% dentro 3σ

Casos de aplicación:



Mediciones físicas: Altura, peso, presión arterial

Errores de medición: En experimentos científicos

Variables económicas: En mercados eficientes a corto plazo

Pruebas de normalidad: Shapiro-Wilk, Kolmogorov-Smirnov, visual con Q-Q plots.

Distribuciones Sesgadas: Asimetría en Datos Reales

La mayoría de datos del mundo real exhiben **asimetría**, donde la distribución no es simétrica alrededor del centro.

Sesgo positivo (right-skewed): Cola larga hacia la derecha

Ejemplos: Ingresos, precios de vivienda, tiempos de respuesta

Media > Mediana > Moda

Interpretación: Pocos valores muy altos elevan la media

Sesgo negativo (left-skewed): Cola larga hacia la izquierda

Ejemplos: Tasas de finalización, edades de fallecimiento

Media < Mediana < Moda

Interpretación: Pocos valores muy bajos deprimen la media

Distribuciones Multimodales: Múltiples Poblaciones

Las distribuciones multimodales indican **mezclas de poblaciones** diferentes dentro del mismo dataset.

Causas comunes:

Segmentos demográficos: Jóvenes vs adultos vs seniors

Categorías de producto: Productos premium vs estándar

Períodos temporales: Comportamiento diferente por temporada

Detección: Histogramas con múltiples picos, análisis de clustering.

Task 2: Medidas de Forma: Asimetría y Curtosis (10 minutos)

La asimetría y curtosis cuantifican la **forma** de la distribución más allá de medidas de tendencia central y dispersión.

Asimetría (Skewness): Medida de Simetría

La asimetría mide qué tan **asimétrica** es la distribución alrededor de su media.

Fórmula: $\gamma = \frac{\sum [(x_i - \mu)/\sigma]^3}{n}$



Interpretación:

$\gamma = 0$: Distribución perfectamente simétrica (normal)

$\gamma > 0$: Sesgo positivo (cola derecha más larga)

$\gamma < 0$: Sesgo negativo (cola izquierda más larga)

Rango típico: -3 a +3, valores extremos indican distribuciones muy sesgadas.

Implicaciones prácticas:

Sesgo positivo: La media sobreestima el valor típico

Sesgo negativo: La media subestima el valor típico

Elección de medidas: Usar mediana en lugar de media para medidas centrales

Curtosis (Kurtosis): Medida de "Colas Pesadas"

La curtosis mide la "**pesadez**" de las colas comparada con una distribución normal.

Fórmula: $\kappa = \frac{\sum [(x_i - \mu)/\sigma]^4}{n - 3}$

Interpretación:

$\kappa = 0$: Curtosis normal (mesocúrtica)

$\kappa > 0$: Colas más pesadas (leptocúrtica) - más outliers extremos

$\kappa < 0$: Colas más ligeras (platicúrtica) - menos valores extremos

Ejemplos:

Distribución normal: $\kappa = 0$

Distribución t-Student: $\kappa > 0$ (colas pesadas)

Distribución uniforme: $\kappa < 0$ (colas ligeras)

Significado práctico:

Alta curtosis: Mayor probabilidad de valores extremos

Baja curtosis: Distribución más "aplastada", menos outliers

Task 3: Detección Sistemática de Outliers (8 minutos)

Los outliers son valores que **se desvían significativamente** del patrón general, requiriendo métodos tanto estadísticos como de dominio para su identificación.

Métodos Estadísticos para Outliers



Método del rango intercuartílico (IQR):

```
# Calcular Límites
Q1 = df['variable'].quantile(0.25)
Q3 = df['variable'].quantile(0.75)
IQR = Q3 - Q1

limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

# Identificar outliers
outliers = df[(df['variable'] < limite_inferior) | (df['variable'] > limite_superior)]
```

Ventajas: Robusto, no asume distribución específica, fácil de interpretar.

Método Z-Score:

```
from scipy import stats

# Calcular z-scores
z_scores = stats.zscore(df['variable'])

# Outliers: |z| > 3
outliers = df[abs(z_scores) > 3]
```

Ventajas: Estándar estadístico, útil para distribuciones aproximadamente normales.

Estrategias de Manejo de Outliers

Eliminación: Solo cuando outliers son claramente errores de medición.

```
df_sin_outliers = df[abs(z_scores) <= 3]
```

Transformación: Aplicar logaritmos o otras transformaciones.



```
df['variable_log'] = np.log1p(df['variable'])
```

Winsorización: Reemplazar outliers con percentiles extremos.

```
from scipy.stats.mstats import winsorize
```

```
df['variable_winsorized'] = winsorize(df['variable'], limits=[0.05, 0.05])
```

Análisis separado: Analizar outliers como grupo separado.

```
outliers_group = df[abs(z_scores) > 3]  
normal_group = df[abs(z_scores) <= 3]
```

Consideraciones de Dominio

¿Son errores o señales?:

Errores: Valores físicamente imposibles (edades negativas)

Señales: Valores extremos válidos (compras de lujo, eventos raros)

Contexto temporal: Un outlier en contexto histórico puede ser normal en contexto actual.

Segmentación: Lo que es outlier en un segmento puede ser normal en otro.

