



# Pruebas de Hipótesis y su Aplicación Práctica - Día 2

pending

40 min

## Learning Objectives

- 1 Comprender el marco formal para validar hipótesis con datos estadísticos
- 2 Distinguir entre errores tipo I y tipo II en pruebas estadísticas
- 3 Aplicar pruebas t para comparación de medias en contextos empresariales

Theory

Practice

Quiz

Evidence

## Activities and Learning

### Task 1: Marco de Pruebas de Hipótesis (10 minutos)

Las pruebas de hipótesis proporcionan un método sistemático y riguroso para tomar decisiones basadas en datos, minimizando el riesgo de conclusiones erróneas.

Hipótesis Nula vs Hipótesis Alternativa

**Hipótesis nula ( $H_0$ ):** La hipótesis de "no hay diferencia" o "no hay efecto".

**Ejemplos:**

- "La tasa de conversión del sitio web nuevo es igual a la del sitio antiguo"
- "No hay diferencia en satisfacción entre clientes nuevos y existentes"
- "El precio promocional no afecta las ventas"

**Hipótesis alternativa ( $H_1$  o  $H_a$ ):** La hipótesis que queremos probar.

**Ejemplos:**

- "La tasa de conversión del sitio web nuevo es mayor"
- "Los clientes nuevos están menos satisfechos"

us English



Sign Out





Dashboard

Career Path

Forms

Profile

**Importante:** Siempre se formula  $H_0$  como la hipótesis conservadora (status quo).

Nivel de Significancia ( $\alpha$ ) y Valor p

**Nivel de significancia ( $\alpha$ ):** Probabilidad máxima de cometer error tipo I que estamos dispuestos a aceptar.

**Valores comunes:** 0.05 (5%), 0.01 (1%), 0.10 (10%)

**Interpretación:** Si  $\alpha = 0.05$ , aceptamos 5% de riesgo de concluir falsamente que hay diferencia

**Valor p:** Probabilidad de observar los datos (o más extremos) si  $H_0$  es verdadera.

**Interpretación:**

$p < \alpha$ : Rechazamos  $H_0$  (evidencia suficiente contra la hipótesis nula)

$p \geq \alpha$ : No rechazamos  $H_0$  (no hay evidencia suficiente)

**Error común:** "p = 0.06 significa que hay 6% de probabilidad de que  $H_0$  sea falsa" (INCORRECTO)

## Task 2: Errores Tipo I y Tipo II (8 minutos)

Las pruebas estadísticas no son perfectas; siempre existe riesgo de error. Entender estos errores es crucial para interpretación correcta de resultados.

Error Tipo I (Falso Positivo)

**Definición:** Rechazar  $H_0$  cuando  $H_0$  es realmente verdadera.

**Probabilidad:**  $\alpha$  (nivel de significancia)

**Ejemplo:** Concluir que un nuevo medicamento funciona cuando realmente no funciona

**Consecuencias:** Implementar cambios innecesarios, desperdiciar recursos

**Factores que afectan  $\alpha$ :**

**Tamaño de muestra:** Muestras grandes reducen  $\alpha$  para mismo efecto

**Variabilidad:** Más variabilidad aumenta  $\alpha$

**Elección de  $\alpha$ :** Más conservador = menor  $\alpha$

Error Tipo II (Falso Negativo)

**Definición:** No rechazar  $H_0$  cuando  $H_0$  es realmente falsa.

**Probabilidad:**  $\beta$

**Ejemplo:** No detectar que un nuevo medicamento funciona cuando realmente funciona



Sign Out





Dashboard

Career Path

Forms

Profile

**Consecuencias:** Perder oportunidades, no implementar mejoras efectivas**Poder estadístico:**  $1 - \beta$  = Probabilidad de detectar efecto real cuando existe.

Matriz de Confusión Estadística

Realidad →	Decisión ↓	$H_0$ Verdadera	$H_1$ Verdadera
No rechazar $H_0$		Decisión correcta $(1-\alpha)$	Error Tipo II $(\beta)$
Rechazar $H_0$		Error Tipo I $(\alpha)$	Decisión correcta $(1-\beta)$

### Equilibrio $\alpha$ vs $\beta$ :

**Estudios exploratorios:**  $\alpha$  más laxo (0.10) para detectar señales débiles**Decisiones críticas:**  $\alpha$  muy conservador (0.01) para evitar falsos positivos**Poder:** Aumentar tamaño de muestra reduce tanto  $\alpha$  como  $\beta$ 

## Task 3: Pruebas t para Comparación de Medias (12 minutos)

Las pruebas t son las herramientas más comunes para comparar medias entre grupos, especialmente útiles cuando no conocemos la varianza poblacional.

Prueba t de Una Muestra

Compara la media de una muestra con un valor conocido o hipotético.

**Fórmula:**  $t = (\bar{x} - \mu_0) / (s/\sqrt{n})$

$\bar{x}$ : Media muestral

$\mu_0$ : Valor hipotético bajo  $H_0$

$s$ : Desviación estándar muestral

$n$ : Tamaño de muestra

### Aplicación práctica:

```
from scipy import stats
import numpy as np

# Datos: Satisfacción de clientes después de cambio de servicio
satisfaccion = np.array([4.2, 3.8, 4.5, 4.1, 3.9, 4.3, 4.0, 4.4, 3.7, 4.6])

# Prueba: ¿Es la satisfacción significativamente mayor que 4.0?
t_stat, p_value = stats.ttest_1samp(satisfaccion, 4.0, alternative='greater')

print(f"Estadístico t: {t_stat:.3f}")
```



Sign Out





Dashboard

Career Path

Forms

Profile

```
print(f"Valor p: {p_value:.4f}")
print(f"Conclusión: {'Rechazamos H0' if p_value < 0.05 else 'No rechazamos H0'}")
```

Prueba t de Dos Muestras Independientes

Compara medias de dos grupos independientes.

**Fórmula:**  $t = (\bar{x}_1 - \bar{x}_2) / \sqrt{(s_1^2/n_1 + s_2^2/n_2)}$

**Asunción:** Varianzas iguales (o usar corrección Welch si no)

**Ejemplo empresarial:** Comparar efectividad de dos estrategias de marketing.

```
# Datos: Conversiones de dos campañas de marketing
campana_A = np.random.normal(0.12, 0.03, 100) # 12% conversión, n=100
campana_B = np.random.normal(0.15, 0.04, 120) # 15% conversión, n=120

# Prueba: ¿Es la campaña B significativamente mejor?
t_stat, p_value = stats.ttest_ind(campana_B, campana_A, alternative='greater')

print(f"Media campaña A: {campana_A.mean():.3f}")
print(f"Media campaña B: {campana_B.mean():.3f}")
print(f"Diferencia: {campana_B.mean() - campana_A.mean():.3f}")
print(f"Estadístico t: {t_stat:.3f}")
print(f"Valor p: {p_value:.4f}")
```

Prueba t Pareada (Before-After)

Compara medidas antes y después en las mismas unidades.

**Ventajas:** Controla variabilidad individual, más poder estadístico.

**Ejemplo:** Efecto de entrenamiento en productividad.

```
# Datos pareados: Productividad antes y después de entrenamiento
antes = np.random.normal(85, 10, 50)
despues = antes + np.random.normal(5, 8, 50) # Mejora promedio de 5 puntos

# Prueba pareada
t_stat, p_value = stats.ttest_rel(despues, antes, alternative='greater')

print(f"Productividad antes: {antes.mean():.1f}")
```



Sign Out



[Dashboard](#)[Career Path](#)[Forms](#)[Profile](#)

```
print(f"Productividad después: {despues.mean():.1f}")
print(f"Mejora promedio: {despues.mean() - antes.mean():.1f}")
print(f"Estadístico t: {t_stat:.3f}")
print(f"Valor p: {p_value:.4f}")
```

## Consideraciones Prácticas

**Tamaño del efecto:** Más importante que significancia estadística.

**Cohen's d:**  $d = (\mu_1 - \mu_2) / \sigma$  (pooled)

**Interpretación:**  $d = 0.2$  (pequeño),  $0.5$  (medio),  $0.8$  (grande)

**Tamaño de muestra:** Afecta poder estadístico.

**Fórmula aproximada:**  $n \approx 16 / d^2$  para detectar efecto de tamaño d

### Asunciones de pruebas t:

**Normalidad:** Datos aproximadamente normales ( $n \geq 30$  ayuda)

**Independencia:** Observaciones independientes

**Homoscedasticidad:** Varianzas similares (para pruebas independientes)

[Sign Out](#)