

# Regresión Lineal Simple para Modelado Predictivo - Día 4

Change Status

pending 40 min

## Learning Objectives

- 1 Estimar parámetros de regresión lineal e interpretar coeficientes correctamente
- 2 Evaluar bondad de ajuste con métricas apropiadas ( $R^2$ , RMSE)
- 3 Diagnosticar problemas comunes en modelos lineales y validar supuestos

Theory

Practice

Quiz

Evidence

## Activities and Learning

### Task 1: Fundamentos Matemáticos de la Regresión Lineal (10 minutos)

La regresión lineal modela la relación entre una variable dependiente (Y) y variables independientes (X) asumiendo una relación lineal.

El Modelo Matemático

**Ecuación básica:**  $Y = \beta_0 + \beta_1 X + \epsilon$

Donde:

- Y:** Variable dependiente (lo que queremos predecir)
- X:** Variable independiente (predictor)
- $\beta_0$ :** Intercepto (valor de Y cuando X = 0)
- $\beta_1$ :** Pendiente (cambio en Y por unidad de X)
- $\epsilon$ :** Error residual (variabilidad no explicada)
- Método de Mínimos Cuadrados Ordinarios (OLS)

OLS encuentra los coeficientes que minimizan la suma de errores cuadráticos:

**Fórmula de  $\beta_1$ :**  $\beta_1 = \frac{\sum((x_i - \bar{x})(y_i - \bar{y}))}{\sum((x_i - \bar{x})^2)}$  **Fórmula de  $\beta_0$ :**  $\beta_0 = \bar{y} - \beta_1 \bar{x}$

**Ventajas de OLS:**

- Propiedad BLUE:** Mejor estimador lineal insesgado
- Mínima varianza:** Entre todos los estimadores lineales insesgados
- Fácil de interpretar:** Coeficientes tienen significado intuitivo

### Task 2: Estimación e Interpretación de Coeficientes (10 minutos)

Los coeficientes de regresión deben interpretarse en contexto, considerando unidades y significancia estadística.

Interpretación del Intercepto ( $\beta_0$ )

**Significado:** Valor esperado de Y cuando X = 0. **Consideraciones:**

- Significativo solo si X=0 es plausible:** No interpretar intercepto si X=0 está fuera del rango de datos
- Escalado:** Afectado por unidades de medición
- Contexto:** Puede no tener significado práctico
- Interpretación de la Pendiente ( $\beta_1$ )

**Significado:** Cambio esperado en Y por cada unidad adicional de X. **Ejemplos:**

- Ventas = 1000 + 50 × (gasto\_publicidad) → Cada \$1 extra en publicidad aumenta ventas en \$50
- Satisfacción = 3.2 + 0.8 × (calidad\_servicio) → Cada punto de calidad aumenta satisfacción en 0.8 puntos

**Consideraciones importantes:**

- Unidades:** Interpretación depende de unidades de X e Y
- Rango de validez:** Coeficiente válido solo dentro del rango observado de X
- Ceteris paribus:** Asume otras variables constantes
- Significancia Estadística

**Prueba t para coeficientes:**  $H_0: \beta_1 = 0$  (variable no contribuye al modelo)

```
# En statsmodels
import statsmodels.formula.api as smf

modelo = smf.ols('ventas ~ gasto_publicidad', data=df).fit()
print(modelo.summary())

# Interpretar:
# coef: valor del coeficiente
```



```
# std err: error estándar
# t: estadístico t
# P>|t|: valor p
# [0.025, 0.975]: intervalo de confianza 95%
```

Task 3: Evaluación de Bondad de Ajuste (10 minutos)

Métricas cuantitativas evalúan qué tan bien el modelo explica los datos y su capacidad predictiva.

Coefficiente de Determinación ( $R^2$ )

Fórmula:  $R^2 = 1 - (SS_{\text{res}} / SS_{\text{tot}})$

**SS\_res:** Suma de cuadrados residuales (errores del modelo)  
**SS\_tot:** Suma de cuadrados totales (variabilidad total)

Interpretación:

**$R^2 = 1.0$ :** Modelo perfecto (explica 100% de variabilidad)  
 **$R^2 = 0.0$ :** Modelo no explica variabilidad (tan bueno como la media)  
 **$R^2$  negativo:** Modelo peor que usar la media

Limitaciones:

**Aumenta con más variables:**  $R^2$  nunca disminuye al añadir predictores  
**No mide calidad predictiva:** Alto  $R^2$  no garantiza buenas predicciones  
**Sensibilidad a outliers:** Puntos extremos pueden inflar  $R^2$  artificialmente  
Error Cuadrático Medio (RMSE) y Error Absoluto Medio (MAE)

**RMSE:**  $\sqrt{(\sum (y_i - \hat{y}_i)^2 / n)}$  - penaliza errores grandes **MAE:**  $\sum |y_i - \hat{y}_i| / n$  - más robusto a outliers

Interpretación práctica:

**RMSE en unidades de Y:** Error típico del modelo en las mismas unidades que Y  
**Comparación con variabilidad:** RMSE vs desviación estándar de Y  
 $R^2$  Ajustado

Fórmula:  $R^2_{\text{ajustado}} = 1 - [(1 - R^2)(n - 1)/(n - p - 1)]$

Donde:

**n:** número de observaciones  
**p:** número de predictores

Ventajas:

**Penaliza complejidad:** Disminuye al añadir predictores que no mejoran el modelo  
**Mejor para comparación:** Entre modelos con diferente número de variables

Task 4: Validación de Supuestos y Diagnóstico (10 minutos)

Los modelos de regresión lineal tienen supuestos que deben verificarse para garantizar validez de inferencias.

Supuestos Clave

**Linealidad:** Relación entre X e Y es lineal. **Verificación:** Gráfico de residuos vs valores ajustados.

**Independencia:** Errores no están correlacionados. **Verificación:** Gráfico de residuos vs orden, prueba de Durbin-Watson.

**Homocedasticidad:** Varianza de errores es constante. **Verificación:** Gráfico de residuos vs valores ajustados, prueba de Breusch-Pagan.

**Normalidad de residuos:** Errores siguen distribución normal. **Verificación:** Q-Q plot, prueba de Shapiro-Wilk.

Diagnóstico Visual

```
import matplotlib.pyplot as plt
import scipy.stats as stats

# Crear gráficos de diagnóstico
fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2, figsize=(12, 10))

# 1. Residuos vs Valores ajustados (Linealidad + homocedasticidad)
ax1.scatter(modelo.fittedvalues, modelo.resid)
ax1.axhline(y=0, color='red', linestyle='--')
ax1.set_xlabel('Valores Ajustados')
ax1.set_ylabel('Residuos')
ax1.set_title('Residuos vs Valores Ajustados')

# 2. Q-Q plot (normalidad)
stats.probplot(modelo.resid, dist="norm", plot=ax2)
ax2.set_title('Q-Q Plot de Residuos')

# 3. Histograma de residuos (normalidad)
ax3.hist(modelo.resid, bins=20, alpha=0.7)
ax3.set_xlabel('Residuos')
ax3.set_ylabel('Frecuencia')
ax3.set_title('Distribución de Residuos')
```



- Dashboard
- Career Path
- Forms
- Profile

```
# 4. Residuos vs Orden (independencia)
ax4.scatter(range(len(modelo.resid)), modelo.resid)
ax4.axhline(y=0, color='red', linestyle='--')
ax4.set_xlabel('Orden de Observación')
ax4.set_ylabel('Residuos')
ax4.set_title('Residuos vs Orden')

plt.tight_layout()
plt.show()
```