

Learning Objectives

- 1 Entender operaciones básicas de limpieza de datos
- 2 Aprender manejo de valores faltantes
- 3 Comprender normalización de datos
- 4 Conocer técnicas de validación básica

Theory

Practice

Evidence

Quiz

Practical exercise to apply the concepts learned.

Ejercicio: Limpiar y validar un dataset de ventas

Dataset con problemas:

```
import pandas as pd
import numpy as np

# Crear datos de ejemplo con problemas
ventas = pd.DataFrame({
    'producto': ['A', 'B', None, 'A', 'C'],
    'precio': [100, None, 150, 100, 200],
    'cantidad': [1, 2, None, 1, 3],
    'fecha': ['2024-01-01', None, '2024-01-03', '2024-01-01', 'invalid']
})

print("Datos originales:")
print(ventas)
print(f"Valores faltantes por columna:\n{ventas.isnull().sum()}")
```

Limpiar datos:

```
def limpiar_datos_ventas(df):
    df_limpio = df.copy()

    # 1. Eliminar duplicados
    df_limpio = df_limpio.drop_duplicates()

    # 2. Imputar valores faltantes
    df_limpio['precio'] = df_limpio['precio'].fillna(df_limpio['precio'].median())
    df_limpio['cantidad'] = df_limpio['cantidad'].fillna(1) # Asumir cantidad mínima

    # 3. Eliminar filas con producto faltante
    df_limpio = df_limpio.dropna(subset=['producto'])

    # 4. Corregir fechas inválidas
    df_limpio['fecha'] = pd.to_datetime(df_limpio['fecha'], errors='coerce')
    df_limpio = df_limpio.dropna(subset=['fecha'])

    # 5. Calcular total
    df_limpio['total'] = df_limpio['precio'] * df_limpio['cantidad']

    return df_limpio

ventas_limpias = limpiar_datos_ventas(ventas)
print("\nDatos limpios:")
print(ventas_limpias)
print(f"\nRegistros finales: {len(ventas_limpias)}")
```

Validar datos limpios:

```
def validar_ventas_limpias(df):
    validaciones = {
        'sin_faltantes': df.isnull().sum().sum() == 0,
        'precios_positivos': (df['precio'] > 0).all(),
        'cantidades_positivas': (df['cantidad'] > 0).all(),
        'fechas_validas': pd.api.types.is_datetime64_any_dtype(df['fecha']),
        'total_correcto': np.allclose(df['total'], df['precio'] * df['cantidad'])
    }
```



- Dashboard
- Career Path
- Forms
- Profile
- Support

```
print("Validaciones:")
for check, passed in validaciones.items():
    status = "✅" if passed else "❌"
    print(f" {status} {check}")

return all(validaciones.values())

es_valido = validar_ventas_limpias(ventas_limpias)
print(f"\nDataset válido: {es_valido}")
```

Verificación: ¿Cuándo deberías eliminar datos faltantes vs imputarlos? ¿Qué tipos de validaciones son más importantes para diferentes tipos de datos?

Requerimientos:

- Pandas instalado
- Conocimiento básico de manipulación de datos
- Comprensión de calidad de datos